# Déployez un modèle dans le cloud Ilaria Mereu Canestra di Frutta - Caravaggio

### Mission

Notre client: Fruits! Start-up de l'AgriTech

### Nos objectifs:

Réaliser un moteur de classification d'images de fruits entièrement déployé dans le cloud.

Nous développerons un prototype de ce moteur:

- structuré selon une architecture Big Data
- RGPD compliant
- Utilisant Pyspark (adapté à un passage à l'échelle)



### Sommaire

- I. Description de la problématique
- 2. La plateforme et ses configurations
- 3. Dataset
- 4. Résultats
- 5. Conclusions



# I. Description de la problématique

# Description de la problématique

Nous disposons d'un jeu d'images de 131 fruits et légumes classifiées sous le nom du fruit même. Exemple:

Apple Braeburn	Grape Blue	Pear Monster
Apple Crimson Snow	Grape Pink	Pear Red
Apple Golden 1	Grape White	Pear Stone
Apple Golden 2	Grape White 2	Pear Williams
Apple Golden 3	Grape White 3	Pepino

Chaque dossier ainsi nommé contient ~10<sup>2</sup> images.

Par exemple, dans le dossier "Pomegranate" (grenade) nous trouvons ~500 images de ce type:

À partir de ce jeu de données, notre objectif est:

 prédisposer un modèle de type CNN afin qu'il reconnaisse et classifie d'autres images de fruits.



• déployer ce modèle dans une infrastructure Big Data.



# Déployer dans le cloud

Notre infrastructure Big Data doit se composer de :

- 1. une architecture de ressources de calcul (EMR)
- 2. un système d'accès et de exploitation de ces ressources (CLI ou UI)
- 3. un système de stockage à accès controlé (S3)
- 4. des politiques d'accès pour les utilisateurs (IAM)

Nous avons utilisé la plateforme Amazon Web Services.



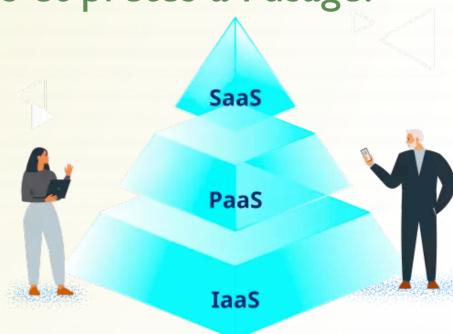




# Déployer dans le cloud

AWS et les autres plateformes concurrentes proposent différentes solutions qui se différencient pour:

- une liberté variable de configurer les ressources allouées
- une offre de solutions déjà configurées et prêtes à l'usage.
- I. laaS
- 2. Paas
- 3. Saas



Au sein de AWS, nous avons développé notre projet sous forme d'instance notebook ml.t3.medium sur AWS Sagemaker.



## Big Data

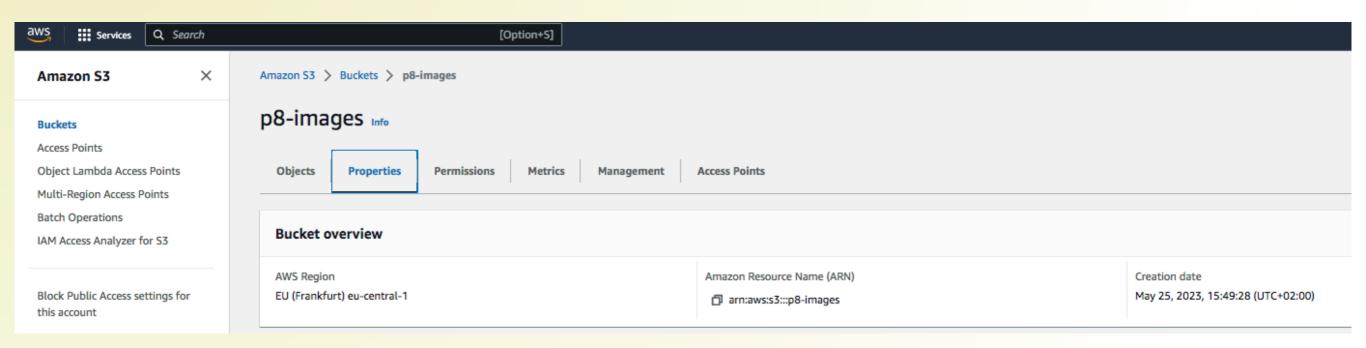
Valeur Clinically relevant data **V**alue Longitudinal studies Volume High-throughput technologies Volume Continuous monitoring of vital signs Vitesse High-speed processing for fast clinical decision support Velocity Increasing data generation rate by the health infrastructure Variété Heterogeneous and unstructured data sources Variety Differences in frequencies and taxonomies Véridicité Data quality is unreliable Veracity Data coming from uncontrolled environments Variabilité Seasonal health effects and disease evolution **V**ariability Non-deterministic models of illness and health



# Dataset

### Dataset

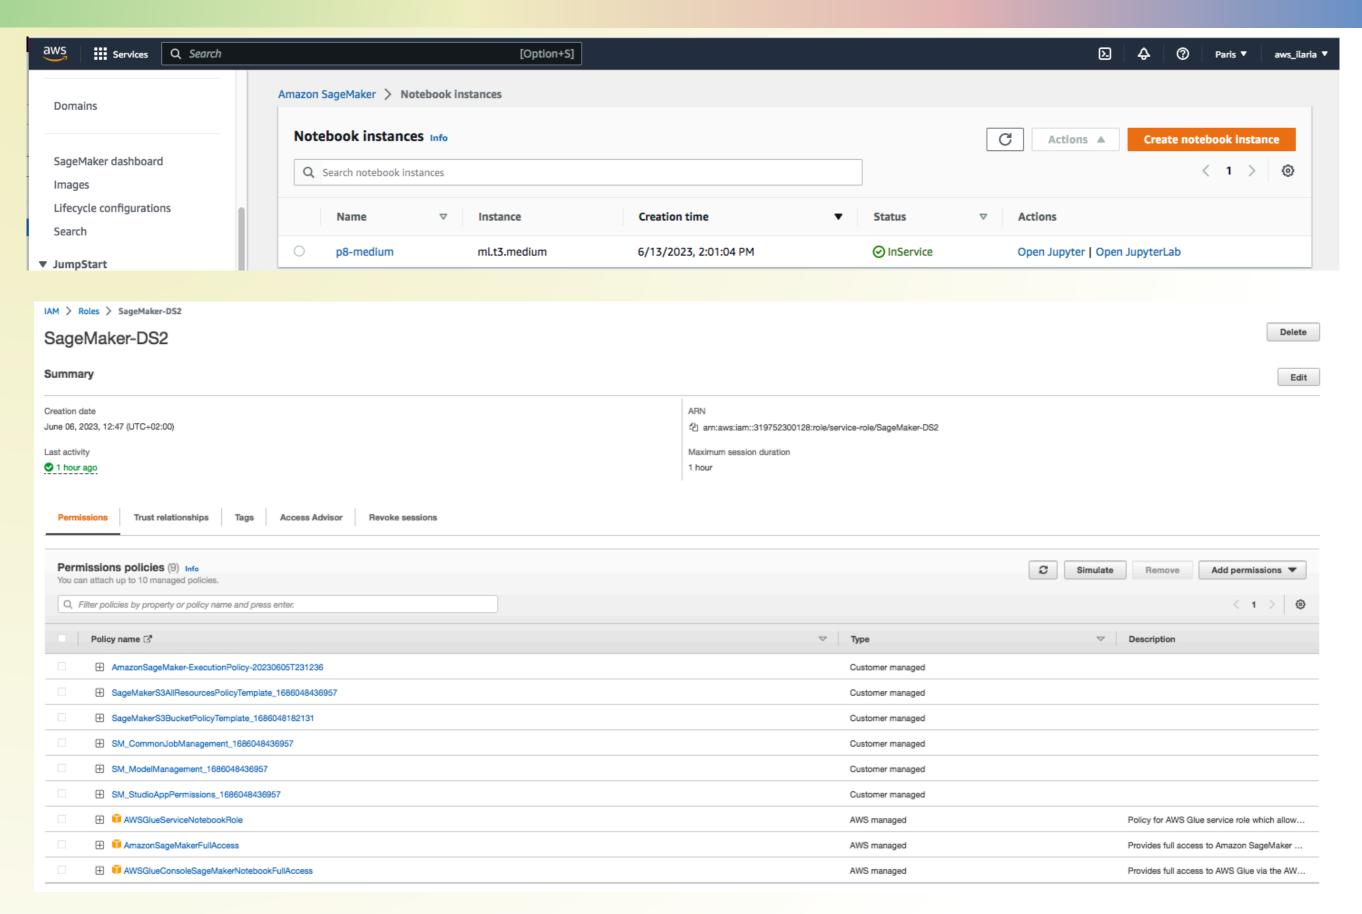
Nous avons utilisé un dataset réduit à cinq images pour cinq espèces. Il est stocké sur AWS S3, région eu-central-1.







# Instance Sagemaker



# Instance Sagemaker

### Notre notebook:

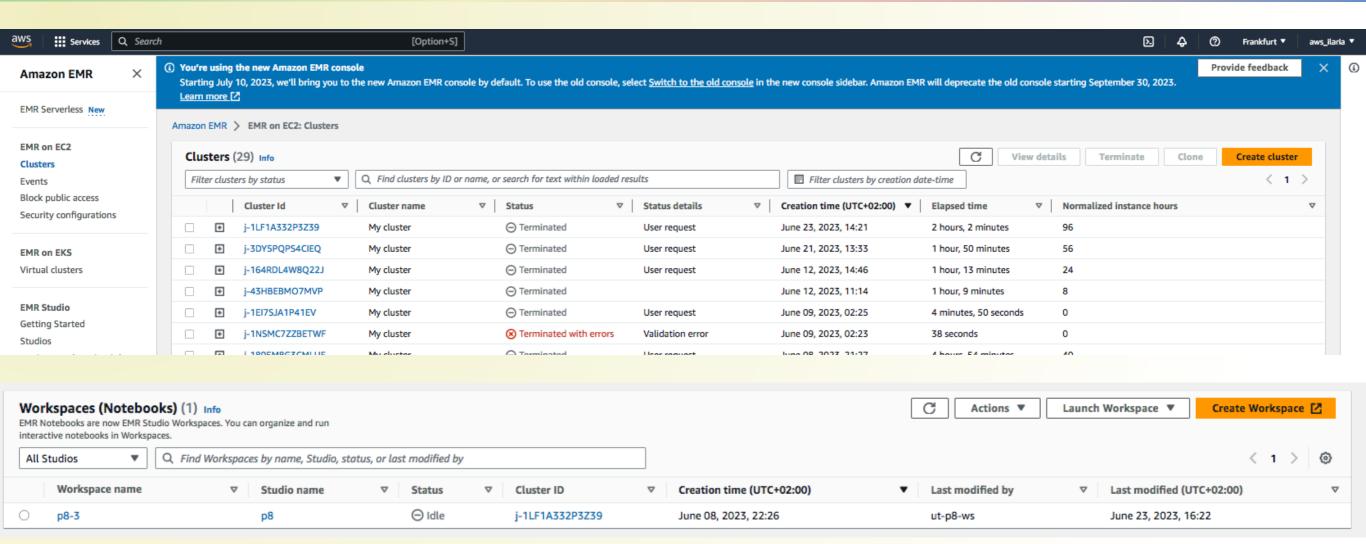
- accède aux images
- extrait leur classification du nom du dossier et leur features avec un mod<u>è</u>le de type VGG I 6
- réalise une réduction de dimensions
- sauvegarde les résultats sur S3:

```
df_pandas.head()
write_dataframe_to_csv_on_s3(df_pandas, S3_bucket, f'{OUT_FOLDER}/resultats_pca.csv')
```

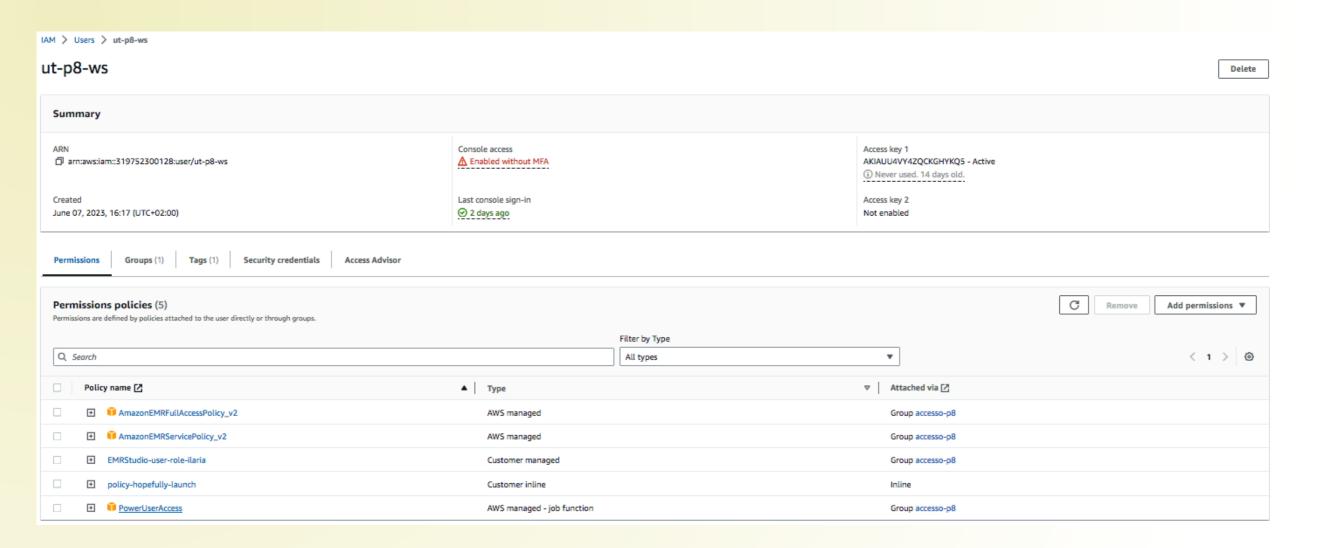
Writing 25 records to Results/resultats\_pca.csv on bucket s3a://p8-images



# Non retenue: EMR Workspace



# Non retenue: EMR Workspace



# Conclusions

### Conclusions

### Il émerge la nécessité d'expertises spécifiques:

- Coté langage: Pyspark s'appuie sur Spark, qui est écrit en Scala, qui s'appuie sur JVM. Déboggage problématique car les erreurs sont difficiles à interpréter.
- Coté plateforme: les solutions AWS sont en mise à jour continue, le support payant semble indispensable pour une mise en production efficace.



# Merci